第一次练习课参考答案

黄嘉平
2026.4

一、基础练习

1. 将下列数字以向量的形式保存于变量 **x**。

```
x <- c(37, 45, 45, 46, 29, 44, 30, 42, 43, 39)
x
[1] 37 45 45 46 29 44 30 42 43 39
```

2. 根据公式计算 **x** 的样本方差。

```
varx <- sum((x - mean(x))^2) / 9
varx
[1] 38.44444
```

3. 使用 **var()** 函数再次计算 **x** 的方差，确认结果和上一问一致。

```
varx - var(x)
[1] 0
```

4. 假设 **x** 中的数值是十名大四女生的一分钟仰卧起坐体测数据。将 **x** 以数据框（data frame）的形式保存于变量 **y**，并将列名称设定为 **Situp**。

```
y <- data.frame(Situp = x)
y
   Situp
1     37
2     45
3     45
4     46
5     29
6     44
7     30
8     42
9     43
10    39
```

5. 向 **y** 中添加一个空列，名称为 **Score**。

```r
y[, 'Score'] <- NA
y
```

```
   Situp Score
1     37    NA
2     45    NA
3     45    NA
4     46    NA
5     29    NA
6     44    NA
7     30    NA
8     42    NA
9     43    NA
10    39    NA
```

6. 查阅《国家学生体质健康标准（2014 年修订）》中关于大三大四女生一分钟仰卧起坐的评分标准，并对 **y** 中的每个 **Situp** 数据进行评分，将评分结果保存在 **Score** 列中。

```r
y$Score <- (ceiling(y$Situp/2) + 16) * 2
y
```

```
   Situp Score
1     37    70
2     45    78
3     45    78
4     46    78
5     29    62
6     44    76
7     30    62
8     42    74
9     43    76
10    39    72
```

（这里用了 **ceiling()** 函数，其作用是向上取整，即找出不小于输入值的整数中最小的那个。由于数据中仰卧起坐数的取值范围对应的分数都处于及格等级范围内，我们只需要一个简单的公式即可计算分数。如果想对应更广泛的分数段，则此代码不能直接使用。）

二、数据的导入和操作

下载 fitness.csv 文件并回答下面的问题。此文件中包含了 145 名大四女生的假想体测数据，其中列名称 Lungcap 代表肺活量，Run 代表 50 米跑，Jump 代表立定跳远，Sitreach 代表坐位体前屈，Situp 代表一分钟仰卧起坐。

1. 使用 **read.csv()** 函数将 fitness.csv 文件的内容导入并保存在 **Fit** 变量中。

这里默认建立了项目（project）。在项目所在的文件夹中新建文件夹 data，并将数据文件放在 data 中。如果文件放在其他位置，或者没有建立项目，则下面代码中的文件路径也需要更改。可搜索“绝对路径”和“相对路径”了解相关概念。

```
Fit <- read.csv("data/fitness.csv")
head(Fit)
```

```
  ID Height Weight Lungcap  Run Jump Sitreach Situp
1  1  167.9   51.2    2318 8.75  170     12.3    37
2  2  160.9   47.9    3183 8.25  190     21.2    45
3  3  157.3   57.0    2677 8.25  165     13.2    45
4  4  167.0   65.0    2579 9.81  190     19.8    46
5  5  162.5   64.0    3282 9.33  190     19.3    29
6  6  163.0   55.0    2443 9.33  180     11.5    44
```

2. 计算每个学生的 BMI 指数并添加在 **`Fit`** 中。

注意在计算 BMI 时用到的身高单位是米，而数据中的单位显然是厘米。

```
Fit$BMI <- Fit$Weight / (Fit$Height / 100)^2
head(Fit)
```

```
  ID Height Weight Lungcap  Run Jump Sitreach Situp      BMI
1  1  167.9   51.2    2318 8.75  170     12.3    37 18.16220
2  2  160.9   47.9    3183 8.25  190     21.2    45 18.50220
3  3  157.3   57.0    2677 8.25  165     13.2    45 23.03655
4  4  167.0   65.0    2579 9.81  190     19.8    46 23.30668
5  5  162.5   64.0    3282 9.33  190     19.3    29 24.23669
6  6  163.0   55.0    2443 9.33  180     11.5    44 20.70082
```

3. 利用 **`plot()`** 函数绘制 BMI 和肺活量之间的散点图。二者之间能观察到什么关系？

```
plot(Fit$BMI, Fit$Lungcap)
```

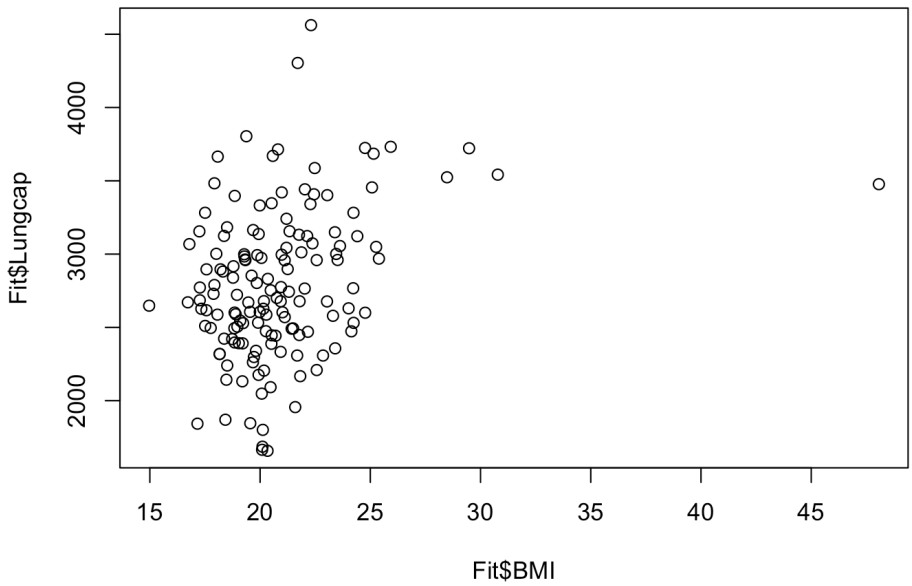

图 1　Fit 数据中 BMI 和肺活量之间的散点图

除了最右侧的点，其他点显示 BMI 和肺活量之间呈现正向线性相关关系。

4. 从上一问的结果中你是否能发现一个明显的异常值？利用条件判断的方式从 **Fit** 中找到该异常值对应的 ID。

观察图 1 可知最右侧的点是明显的异常值，其 BMI 取值大于 45。根据这一特征可以将代码写为

```
Fit[Fit$BMI > 45,]
```

```
   ID Height Weight Lungcap  Run Jump Sitreach Situp      BMI
54 54    158    120    3477 8.82  180     15.3    44 48.06922
```

异常值对应的 ID 为 54。使用 **subset(Fit, BMI > 45)** 也能得到相同的结果。

5. 将不包含上一问中异常值的数据保存在 **Fit2** 中，并重新绘制 BMI 和肺活量之间的散点图。利用 **cor()** 函数分别计算 **Fit** 和 **Fit2** 中 BMI 和肺活量间的相关系数。剔除异常值前后相关系数是否有明显变化？

下面的代码利用了“不等式”的条件判断，其中 **!=** 的含义等同于 $\neq$。这行代码的意思是找出 ID 不为 54 的所有行。可以直接利用 BMI $<$ 45 这一条件。

```
Fit2 <- Fit[Fit$ID != 54,]
plot(Fit2$BMI, Fit2$Lungcap)
```

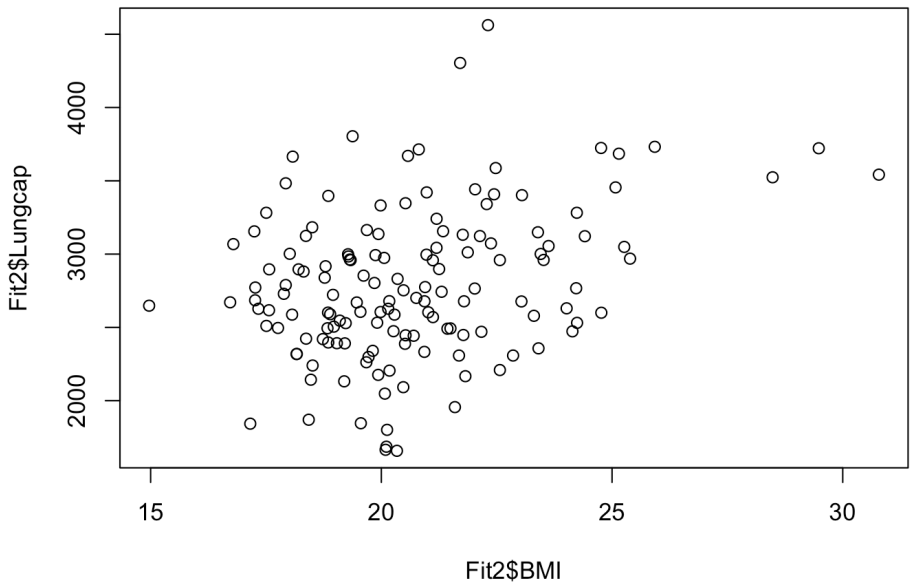

图 2　Fit2 数据中 BMI 和肺活量之间的散点图

```
cor(Fit$BMI, Fit$Lungcap)
[1] 0.3169833
```

```
cor(Fit2$BMI, Fit2$Lungcap)
[1] 0.3291025
```

剔除异常值前后相关系数的差异约为 0.012，变化并不明显。

6. 针对 50 米跑和立定跳远的成绩重复第 3~5 问。

```
plot(Fit$Run, Fit$Jump)
```

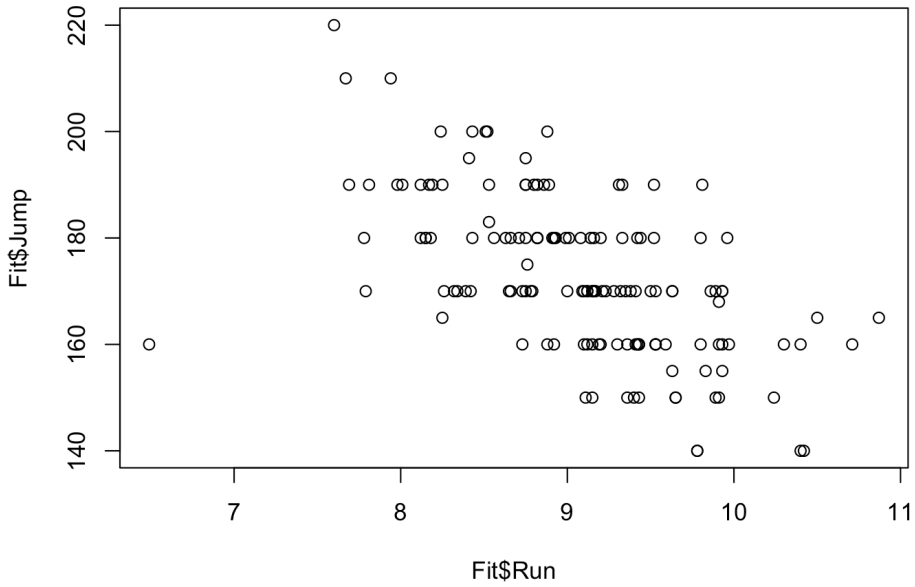

图 3　Fit 数据中 50 米跑和立定跳远之间的散点图

一个明显的极端值是最左侧的点，其短跑成绩小于 7 秒。除此之外，其他点显示跑得快和跳得远之间存在正向线性相关。

```
Fit[Fit$Run < 7,]
```

```
   ID Height Weight Lungcap  Run Jump Sitreach Situp     BMI
62 62    163     51    2132 6.49  160     15.5    43 19.1953
```

异常值的 ID 是 62。

```
Fit3 <- Fit[Fit$ID != 62,]
plot(Fit3$Run, Fit3$Jump)
```

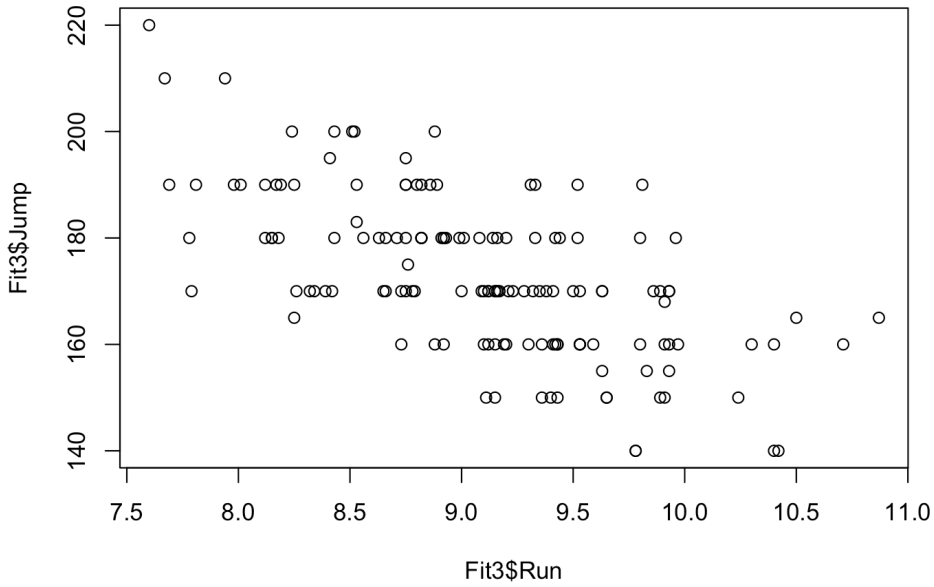

图 4　Fit3 数据中 50 米跑和立定跳远之间的散点图

```
cor(Fit$Run, Fit$Jump)
[1] -0.5865114
```

```
cor(Fit3$Run, Fit3$Jump)
[1] -0.6414532
```

剔除异常值前后相关系数的差异约为 0.055，变化并不明显。