

第三次练习课参考答案

黄嘉平
2026.5

一、成分分解

本题中继续使用 `canadian_gas` 数据集。该数据集包含了 1960 年 1 月至 2005 年 2 月间加拿大的天然气产量月度数据（保存在 `Volume` 变量中），数据单位是十亿立方米。

1. 分别用传统分解法（加法模型和乘法模型）、X-11、SEATS、STL 法进行成分分解并绘图。比较各种方法的分解结果，并描述它们的区别。

首先给出五种方法的代码：

```
library(fpp3)
```

```
## 传统分解法加法模型
```

```
cgas_dclassic_add <- canadian_gas |>
  model(
    classical_decomposition(Volume, type = "additive")
  ) |>
  components()
cgas_dclassic_add |>
  autoplot() +
  labs(
    title = "Classical Additive Decomposition of
            Canadian Gas Production"
  )
```

```
## 传统分解法乘法模型
```

```
cgas_dclassic_multi <- canadian_gas |>
  model(
    classical_decomposition(Volume, type = "multiplicative")
  ) |>
  components()
cgas_dclassic_multi |>
  autoplot() +
  labs(
    title = "Classical Multiplicative Decomposition of
            Canadian Gas Production"
  )
```

```
## X-11
cgas_dx11 <- canadian_gas |>
  model(
    x11 = X_13ARIMA_SEATS(Volume~ x11())
  ) |>
  components()
cgas_dx11 |>
  autoplot() +
  labs(
    title = "X-11 Decomposition of Canadian Gas Production"
  )
```


```
## SEATS
cgas_dseats <- canadian_gas |>
  model(
    seats = X_13ARIMA_SEATS(Volume~ seats())
  ) |>
  components()
cgas_dseats |>
  autoplot() +
  labs(
    title = "SEATS Decomposition of Canadian Gas Production"
  )
```

```
## STL
cgas_dstl <- canadian_gas |>
  model(
    STL(Volume, robust = TRUE) # 注意这里启用了 robust 设定
  ) |>
  components()
cgas_dstl |>
  autoplot() +
  labs(
    title = "STL Decomposition of Canadian Gas Production"
  )
```

下面是五种方法的分解图：


Classical Additive Decomposition of Canadian Gas Production

Volume = trend + seasonal + random



Classical Multiplicative Decomposition of Canadian Gas Production


Volume = trend * seasonal * random



在这一序列中，传统分解法的加法模型和乘法模型并没有太大区别，它们的季节项都是固定的，因此剩余项显示出明显的方差变化，同时也包含了一部分季节特征。


X-11 Decomposition of Canadian Gas Production

Volume = trend * seasonal * irregular



SEATS Decomposition of Canadian Gas Production


Volume = f(trend, seasonal, irregular)



X-11 和 SEATS 都适用于宏观经济数据，在此序列上的表现也比较相似。它们的季节项变动幅度并不固定，且幅度的大小和原序列的变化幅度并不一致，而剩余项则更接近白噪声。

STL Decomposition of Canadian Gas Production

Volume = trend + season_year + remainder



STL 的季节项虽然也在变化幅度上并不固定，但是和 X-11、SEATS 的变化模式有明显区别，更接近原序列的变化特征。由于代码中指定了稳健估计 (**robust = TRUE**)，部分冲击被剩余项吸收（例如 1988 年附近）。

2. 针对前一问中五种分解结果中的剩余项分别绘制自相关图（注意不同分解结果中保存剩余项的变量名称）。各种方法是否有效去除了趋势和季节特征？

首先是绘图代码：

```
cgas_dclassic_add |>
  ACF(random) |>
  autoplot() +
  labs(title = "Classical Additive")

cgas_dclassic_multi |>
  ACF(random) |>
  autoplot() +
  labs(title = "Classical Multiplicative")

cgas_dx11 |>
  ACF(irregular) |>
  autoplot() +
  labs(title = "X-11")
```

```

cgas_dseats |>
  ACF(irregular) |>
  autoplot() +
  labs(title = "SEATS")




```


```

cgas_dstl |>
  ACF(remainder) |>
  autoplot() +
  labs(title = "STL")

```

下面是自相关图：





所有方法都有效去除了趋势。传统分解法的两种方法都包含了明显的周期为 12 期的季节特征。X-11、SEATS 和 STL 都能有效去除季节性，但是剩余项中依然存在自相关特征。

二、预测

本题中使用 **aus_production** 数据集中的水泥（Cement）产量数据。

1. 该序列的起止时间是什么？共包含多少期？

```
aus_cement <- aus_production |> select(Cement)
```

```
aus_cement |> slice(1,n()) # 从第一行和最后一行中了解起止时间
```

```
# A tibble: 2 x 2 [10]
  Cement Quarter
  <dbl> <qtr>
1    465 1956 Q1
2   2401 2010 Q2
```

```
aus_cement |> count() # 获取样本量
```

```
# A tibble: 1 x 1
  n
  <int>
1  218
```

数据起始于 1956 年第一季度，终止于 2010 年第二季度。共包含 218 期。

2. 利用 `slice_head()` 和 `slice_tail()` 函数，将最后 40 个观测值设为测试集，其余观测值设为训练集。

```
cement_train <- aus_cement |>
  slice_head(n = 178) # 定义训练集

cement_test <- aus_cement |>
  slice_tail(n = 40) # 定义测试集
```


3. 针对训练集，分别利用均值法、朴素法、季节性朴素法和漂移法进行拟合，并对未来 40 期（即测试集中的时间点）进行预测。模仿教科书 5.2 节，通过绘图展示预测结果。

```
cement_fit <- cement_train |>
  model(
    Mean = MEAN(Cement),
    Naive = NAIVE(Cement),
    SNaive = SNAIVE(Cement),
    Drift = RW(Cement~ drift())
  ) # 分别拟合四个模型

cement_fc <- cement_fit |>
  forecast(h = 40) # 预测未来 40 期

cement_fc |>
  autoplot(aus_cement, level = NULL) +
  labs(
    y = "1000 tonnes",
    title = "Forecasts for quarterly cement production"
  ) +
  guides(colour = guide_legend(title = "Forecast"))
```

绘图结果见下页。



4. 用 RMSE 和 MAE 测度比较模型的预测准确性。哪个模型表现得最好？

```
accuracy(cement_fc, cement_test)
```

```
# A tibble: 4 × 10
  .model .type      ME  RMSE  MAE  MPE  MAPE  MASE  RMSSE  ACF1
  <chr>  <chr>  <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 Drift  Test   -123.  249.  203. -7.16  10.4   NaN    NaN  0.447
2 Mean   Test    870.  912.  870. 39.7   39.7   NaN    NaN  0.640
3 Naive  Test    62.8  282.  241.  1.23  11.4   NaN    NaN  0.640
4 SNaive Test    149.  293.  251.  5.55  11.5   NaN    NaN  0.791
```

从结果中可知，RMSE 和 MAE 都显示漂移法的预测误差在四种方法中最小。这符合上图中的印象。

三、回归分析

本题中使用 energy.csv 中的数据。此文件中包含了 1953-2023 年间中国的人均能源生产与消费量（包括总量、原煤、原油、电力），但存在缺失值和说明性文字，在使用时需要注意。本数据来源于中国研究数据服务平台（CNRDS）。

考虑用回归方法对人均电力消费量进行分析。被预测变量为人均电力消费量，可用的预测变量为除了人均电力生产量和消费量之外的所有变量（人均电力生产量和消费量几乎没有差异）。综合利用学过的方法找出你认为最好的模型。

本题存在一定的主观性，以下仅为参考答案：


首先我们要对数据进行导入和整理，

- 删除 1952 年的观测值（都是缺失值），同时删除最后一行的说明；
- 变更列名称；
- 将数据转存为 tsibble 类型。

```
energy <- readr::read_csv("data/energy.csv")
energy <- energy |>
  drop_na() |> # 删除包含缺失值的行（第一行和最后一行）
  rename(
    Year = "会计年度",
    PAll = "人均能源生产量_能源总量（千克标准煤）",
    PCoal = "人均能源生产量_原煤（千克）",
    POil = "人均能源生产量_原油（千克）",
    PElec = "人均能源生产量_电力（千瓦时）",
    CAll = "人均能源消费量_能源总量（千克标准煤）",
    CCoal = "人均能源消费量_煤炭（千克）",
    COil = "人均能源消费量_石油（千克）",
    CElec = "人均能源消费量_电力（千瓦时）"
  ) |> # 修改列名称
  mutate(Year = as.numeric(Year)) |> # 将第一列由字符类型转换为数值类型
  select(-PElec) |> # 删除人均电力生产量
  tsibble(index = Year) # 转存为 tsibble 数据
```

然后绘制时序图观察变量的特征。


```
energy |>
  pivot_longer(!Year) |>
  ggplot(aes(Year, value)) +
  geom_line() +
  facet_wrap(vars(name), scales = "free_y", nrow = 4) +
  labs(y="Value")
```



这一步仅是了解数据，对变量选择并不起到决定性作用。接下来通过变量间的相关系数做初步筛选。

```
energy |> GGally::ggpairs(columns = 2:8)
```

绘图结果见下页。通过观察可知，PAil 和所有消费变量都有着极强的相关性 ($\text{Corr} > 0.99$)，为避免多重共线性带来的估计偏差，这里不考虑 CAil, CCoal 和 COil。同时，PAil 和 PCoal 的相关性也极高，因此不考虑 PCoal。剩余变量为 PAil 和 POil。



包含 PAIl 或 POil 的线性回归模型共有三种，且数据中存在趋势，因此所有模型都需加入趋势项。以下为模型拟合的结果。

```
modelfit1 <- energy |>
  model(
    M1 = TSLM(CElec ~ trend() + PAIl),
    M2 = TSLM(CElec ~ trend() + POil),
    M3 = TSLM(CElec ~ trend() + PAIl + POil)
  )
```

可以通过 `report()` 函数查看参数的估计值等信息，这里写出供代码，省略结果的展示。

```

modelfit1 |> select(M1) |> report()
modelfit1 |> select(M2) |> report()
modelfit1 |> select(M3) |> report()

```

下面用 `glance()` 函数调用关于模型拟合优度的相关测度。

```

modelfit1 |> glance() |>
  select(.model, adj_r_squared, AIC, AICc, BIC, CV)
# A tibble: 3 × 6
  .model adj_r_squared    AIC  AICc    BIC      CV
  <chr>      <dbl> <dbl> <dbl> <dbl> <dbl>
1 M1          0.965  834.  835.  843. 126628.
2 M2          0.889  917.  917.  926. 396498.
3 M3          0.977  805.  806.  816. 83397.

```

所有拟合优度测度都认为 M3 是最优模型。

通过 `tidy()` 函数调用系数的估计结果。

```

modelfit1 |> select(M3) |> tidy()
# A tibble: 4 × 6
  .model term          estimate std.error statistic  p.value
  <chr>  <chr>          <dbl>    <dbl>    <dbl>    <dbl>
1 M3    (Intercept)  -418.      77.9     -5.37 1.08e- 6
2 M3    trend()       15.4      10.0      1.54 1.28e- 1
3 M3    PAll           2.17      0.134     16.3 5.67e-25
4 M3    POil          -13.0      2.14     -6.07 6.64e- 8

```

拟合后的模型为

$$\widehat{CElec}_t = -418 + 15.4t + 2.17 PAll_t - 13.0 POil_t.$$


(77.9)
(10.0)
(0.134)
(2.14)

我们继续验证残差的特性。

```

modelfit1 |> select(M3) |> gg_tsresiduals()

```




从图中可以看出，残差序列存在明显的自相关特征，加上每个变量的原序列都显示出相似的增加趋势，因此可以推断变量间存在伪相关，回归模型并不可靠。

接下来，我们利用原序列计算每个变量的增长率，并期待这样做可以去除趋势并获得更好的回归模型。

```
to_growth_rate <- function(x) (difference(x) / lag(x) * 100)
energy_growth <- energy |>
  mutate_at(vars(-Year), to_growth_rate)
```

`mutate_at()` 函数可以对多个序列进行相同操作，这里针对 `Year` 以外的所有序列都计算增长率，而完成此计算的函数为我们自己定义的 `to_growth_rate()`。


```
energy_growth |>
  pivot_longer(!Year) |>
  ggplot(aes(Year, value)) +
  geom_line() +
  facet_wrap(vars(name), scales = "free_y", nrow = 4) +
  labs(y="Value")
```



由图中可见，趋势已经被有效去除。下面查看变量间的相关性。

```
energy_growth |> GGally::ggpairs(columns = 2:8)
```

绘图结果见下页。通过观察可知，与 PAil 存在极强相关性的变量为 PCoal, CAil 和 CCoal (Corr > 0.94)，剔除后剩余变量为 PAil, POil, COil。



包含 PAll、POil 或 COil 的线性回归模型共有七种。以下为模型拟合的结果。


```
modelfit2 <- energy_growth |>
  model(
    M1 = TSLM(CElec ~ PAll),
    M2 = TSLM(CElec ~ POil),
    M3 = TSLM(CElec ~ COil),
    M4 = TSLM(CElec ~ PAll + POil),
    M5 = TSLM(CElec ~ PAll + COil),
    M6 = TSLM(CElec ~ POil + COil),
    M7 = TSLM(CElec ~ PAll + POil + COil)
  )
```



```
modelfit2 |> glance() |>
  select(.model, adj_r_squared, AIC, AICc, BIC, CV)
# A tibble: 7 × 6
  .model adj_r_squared    AIC  AICc    BIC    CV
  <chr>      <dbl> <dbl> <dbl> <dbl> <dbl>
1 M1         0.517  280.  281.  287.  79.4
2 M2         0.533  278.  278.  285.  52.6
3 M3         0.548  276.  276.  282.  52.1
4 M4         0.635  262.  262.  271.  60.9
5 M5         0.619  265.  265.  274.  61.9
6 M6         0.585  271.  271.  280.  50.1
7 M7         0.643  261.  262.  272.  59.9
```

M4 和 M7 明显优于其他模型，但两者之间几乎没有差别，因此可以选择变量更少的 M4。

```
modelfit2 |> select(M4) |> gg_tsresiduals()
```



残差序列类似白噪声，模型比较可靠。

M4 模型的拟合结果为

```
modelfit2 |> select(M4) |> tidy()
```

```
# A tibble: 3 × 6
  .model term      estimate std.error statistic    p.value
  <chr>   <chr>      <dbl>    <dbl>    <dbl>    <dbl>
1 M4     (Intercept)  4.76     0.873     5.45 0.000000783
2 M4     PAll         0.313    0.0701    4.47 0.0000311
3 M4     POil         0.351    0.0733    4.78 0.00000989
```

即

$$\widehat{\text{CElec}}_t^{\text{growth}} = \underset{(0.873)}{4.76} + \underset{(0.0701)}{0.313} \text{PAll}_t^{\text{growth}} + \underset{(0.0733)}{0.351} \text{POil}_t^{\text{growth}}.$$

注：电力消费量通常用来衡量电力需求，是制定宏观经济政策的重要参考依据。影响电力消费量的变量包括常住人口数、人均收入、天气变化、各用电行业发展程度等。本次练习使用的数据中仅包含能源领域的相关变量，因此分析结果应限于学习用途，不能直接应用于现实中的预测。